PROJETO APLICADO I

Análise exploratória das entregas e da satisfação dos clientes da Olist

Etapas 1 e 2

Definição do projeto, proposta analítica e análise exploratória

Henrique Fernandes Corradini

RA: 1077304

Tecnologia em Banco de Dados

Dados históricos: 2016-2018

Documento elaborado em 5 de outubro de 2026

Sumário

Glossário 4
1. Introdução e delimitação 5
1.1 Referencial metodológico . . . 5
2. Etapa 1: definição do projeto 6
2.1 Contexto, necessidade e justificativa . . . 6
2.2 Objetivos e metas . . . 6
2.3 Premissas e responsabilidades . . . 6
3. Etapa 1: cronograma e aquisição dos dados 7
3.1 Cronograma proposto e marcos . . . 7
3.2 Referências de aquisição e limites de uso . . . 7
4. Etapa 2: organização e problema do estudo 8
4.1 Apresentação da empresa . . . 8
4.2 Problema e perguntas específicas . . . 8
5. Metadados: origem, estrutura e recorte 9
6. Dicionário e perfil de todos os atributos 10
6.1 Itens e pagamentos . . . 11
6.2 Avaliações e medidas de origem . . . 12
7. Pipeline e preparação dos dados 13
7.1 Pensamento computacional aplicado . . . 13
7.2 Critérios de qualidade . . . 13
8. Variáveis derivadas e populações analíticas 14
9. AED: qualidade e caracterização geral 15
9.1 Ausências e texto livre . . . 15
10. AED: frequências e evolução dos pedidos 16
10.1 Formas de pagamento e categorias . . . 16
11. AED: posição e dispersão por pedido 17
12. AED: distribuição e outliers 18
13. AED: avaliações e associação com atraso 19
14. AED: pontualidade e avaliações baixas 20
15. AED: diferenças entre estados 21
15.1 Tabela de apoio das 27 UFs . . . 22
16. AED: relações entre variáveis 23
17. AED: valores, dispersão e síntese 24
18. Proposta de solução analítica 25
18.1 Produto e público de uso . . . 25
18.2 Funcionamento e critérios de aceitação . . . 25
19. Limitações e reprodução 26
19.1 Limites da evidência . . . 26
19.2 Materiais de reprodução e verificação . . . 26
Referências 27

Lista de figuras

Figura 1 - Pedidos por mês de compra 16
Figura 2 - Distribuição do tempo de entrega 18
Figura 3 - Frequência das notas selecionadas por pedido 19
Figura 4 - Tempo de entrega por nota de satisfação 19
Figura 5 - Avaliações baixas por faixa de atraso 20
Figura 6 - Percentual de atraso por UF do cliente 21
Figura 7 - Correlações de Pearson entre medidas por pedido 23
Figura 8 - Dispersão de valor dos itens e frete total 24

Lista de tabelas

Tabela 1 - Termos utilizados 4
Tabela 2 - Objetivos específicos e metas verificáveis 6
Tabela 3 - Cronograma das etapas 1 e 2 7
Tabela 4 - Caracterização da Olist e lacunas documentais 8
Tabela 5 - Inventário completo dos arquivos oficiais 9
Tabela 6 - Metadados gerais e validade 9
Tabela 7 - Pedidos: oito atributos e perfil inicial 10
Tabela 8 - Clientes: cinco atributos e perfil inicial 10
Tabela 9 - Itens: sete atributos e perfil inicial 11
Tabela 10 - Pagamentos: cinco atributos e perfil inicial 11
Tabela 11 - Avaliações: sete atributos e perfil inicial 12
Tabela 12 - Medidas dos atributos quantitativos de origem 12
Tabela 13 - Decomposição e implementação do processo 13
Tabela 14 - Regras dos indicadores por pedido 14
Tabela 15 - Coortes e exclusões explícitas 14
Tabela 16 - Auditoria de integridade e ocorrências 15
Tabela 17 - Distribuição dos status em todos os pedidos 16
Tabela 18 - Medidas de posição e intervalo 17
Tabela 19 - Separatrizes e moda 17
Tabela 20 - Medidas de dispersão 17
Tabela 21 - Limites e ocorrências de outliers 18
Tabela 22 - Comparação entre pedidos pontuais e atrasados com avaliação 20
Tabela 23 - Volume, atraso e prazo mediano por UF 22
Tabela 24 - Spearman entre nota e medidas do pedido 23
Tabela 25 - Respostas às perguntas de pesquisa 24
Tabela 26 - Indicadores propostos e regras de uso 25

Glossário

Tabela 1 - Termos utilizados

Termo	Significado no estudo
AED / EDA	Análise exploratória de dados: caracterização, estatísticas e visualizações para compreender a base.
Dataset	Conjunto de dados; neste caso, nove arquivos CSV relacionados.
Metadados	Informações sobre origem, estrutura, significado, período e restrições dos dados.
Granularidade	Unidade de observação de uma tabela. Na tabela analítica, cada linha representa um pedido.
Pipeline	Sequência de aquisição, validação, transformação, integração, análise e apresentação dos dados.
N / n	Número de registros da população analisada ou de um subconjunto, sempre informado no contexto.
NA	Valor ausente; não significa zero nem avaliação negativa.
UM	Unidade monetária original do CSV. Não foi localizado código explícito da moeda na documentação acessada.
IQR	Intervalo interquartil: Q3 menos Q1. Usado na regra de identificação de outliers.
Outlier	Observação fora dos limites Q1 - 1,5 × IQR ou Q3 + 1,5 × IQR; não constitui erro automaticamente.
CV	Coeficiente de variação: desvio padrão dividido pela média, multiplicado por 100.
Pearson / Spearman	Medidas de associação linear / associação monotônica por postos, respectivamente.
Milestone	Marco de conclusão de uma entrega prevista no cronograma.
p.p.	Pontos percentuais: diferença entre dois percentuais.

1. Introdução e delimitação

Este estudo aplica os conceitos de análise exploratória de dados à base pública histórica de pedidos da Olist. Seu propósito é compreender a estrutura dos dados e investigar associações entre entrega, frete e satisfação, oferecendo uma proposta analítica apoiada nas evidências observadas. A análise foi executada em Python; todas as quantidades apresentadas nas seções de resultados foram calculadas a partir dos arquivos oficiais, sem reaproveitar conclusões de notebooks de terceiros.

A organização do documento acompanha as orientações de Projeto Aplicado I e as rubricas fornecidas: capa, sumário, listas de figuras e tabelas, objetivos, cronograma, metadados, proposta analítica, pipeline e AED [1-3]. O suporte conceitual provém das quatro aulas de AED e dos dois prints de aprofundamento [4-7]. As operações tabulares, estatísticas e visualizações ensinadas em R são aqui aplicadas em Python, como solicitado para a etapa 2.

Pergunta central: como prazos de entrega, atrasos e frete se relacionam com as avaliações dos clientes na base histórica da Olist?

Unidade principal de observação: pedido. Não se confundem linhas de itens, pagamentos ou avaliações com o número de pedidos. O conteúdo está limitado às etapas 1 e 2: definição do projeto, proposta de solução e exploração dos dados. Não contém vídeo, apresentação final ou produtos de encerramento das etapas 3 e 4.

Trata-se de estudo educacional descritivo. A base é um recorte disponibilizado pela organização, sem desenho amostral documentado na fonte consultada. Portanto, os resultados caracterizam esse recorte, não a totalidade do comércio eletrônico brasileiro, a operação atual da Olist ou todos os seus clientes.

1.1 Referencial metodológico

As aulas apresentam o CRISP-DM como referência de processo, a organização tabular Tidy, a distinção entre variáveis quantitativas e categóricas e a combinação de estatística com visualização [4-7]. O projeto aplica entendimento do negócio, entendimento dos dados e preparação dos dados, com exploração descritiva. Não apresenta um modelo preditivo treinado nem sua implantação como entregas concluídas.

Médias e medianas são interpretadas conjuntamente, considerando a sensibilidade da média aos extremos. Notas de satisfação são tratadas como ordinais: frequências, mediana e moda são mais diretamente interpretáveis que uma média de notas. Correlação não é prova de causalidade [6,12]. As escolhas gráficas seguem as perguntas: linhas para evolução, histograma e boxplot para distribuição, barras para quantidades e dispersão/mapa de calor para relações [7,13,14].

2. Etapa 1: definição do projeto

2.1 Contexto, necessidade e justificativa

A base descreve pedidos feitos na Olist Store em diferentes marketplaces brasileiros, com itens, pagamentos, datas de entrega e avaliações [8]. Nesse contexto, a necessidade analítica é transformar registros dispersos em indicadores consistentes, distinguindo o tempo de entrega do cumprimento do prazo prometido. A existência de um problema operacional específico não é presumida: a AED identifica padrões e situações que merecem investigação.

A Olist foi escolhida pela disponibilidade de dados reais publicados pela própria organização, pela combinação de variáveis logísticas e de satisfação e pelo volume suficiente para comparações descritivas. A escolha não implica afirmar que a empresa possui a maior base dentre todos os repositórios indicados nas aulas.

2.2 Objetivos e metas

Objetivo geral: caracterizar os pedidos da base pública da Olist e investigar a associação entre prazo de entrega, atraso, frete e avaliações dos clientes, estruturando uma proposta de relatório analítico para apoiar investigações operacionais.

Tabela 2 - Objetivos específicos e metas verificáveis

Objetivo	Meta / evidência
Caracterizar a base	Inventariar os nove arquivos; documentar os 32 atributos dos cinco arquivos selecionados.
Preparar a integração	Construir uma linha por pedido, validar chaves e reconciliar os totais de itens, frete e pagamentos.
Avaliar a qualidade	Quantificar ausências, repetições, inconsistências de datas e divergências de valores, sem imputação silenciosa.
Descrever logística e valores	Apresentar medidas de posição, dispersão, distribuição, percentis e outliers com denominadores definidos.
Relacionar entrega e satisfação	Comparar notas e avaliações baixas entre pedidos pontuais e atrasados; calcular associações apropriadas.
Propor o produto analítico	Definir indicadores, regras de cálculo, pipeline e critérios de uso, sem prometer melhoria não medida.

2.3 Premissas e responsabilidades

Premissas: fonte pública acessível; uso educacional não comercial; preservação da versão adquirida; ausência de dados operacionais complementares; indicadores interpretados apenas no recorte histórico. A responsabilidade pelo estudo e pela revisão das entregas é de Henrique Fernandes Corradini.

3. Etapa 1: cronograma e aquisição dos dados

3.1 Cronograma proposto e marcos

O calendário de entregas estabelece os marcos de 20/09, 05/10, 29/11 e 13/12, respectivamente para as etapas 1 a 4. A entrega de 05/10 reúne a proposta analítica e a análise exploratória, complementando o documento da etapa 1, e requer a atualização do GitHub com os scripts em Python. As etapas 3 e 4 constam apenas como marcos futuros; seus produtos não integram este documento. Os períodos abaixo organizam as atividades planejadas, sem constituir registro de execução retrospectiva.

Tabela 3 - Cronograma das etapas 1 e 2

Período	Atividades	Responsável	Marco
Até 20/09	Escolher empresa; delimitar problema, objetivos e premissas; verificar base, licença e metadados; revisar documento inicial	Henrique	Entrega 1: 20/09
21/09-25/09	Preparar pipeline, integrar arquivos e verificar qualidade dos dados	Henrique	Tabela analítica validada
26/09-30/09	Calcular estatísticas, produzir gráficos e interpretar associações	Henrique	Análise exploratória
01/10-04/10	Consolidar proposta analítica e notebook; organizar e atualizar o GitHub; conferir rubricas	Henrique	Documento e scripts revisados
05/10	Entregar documento complementado com proposta analítica e análise exploratória	Henrique	Entrega 2: 05/10

Marcos subsequentes do calendário: etapa 3 em 29/11 e etapa 4 em 13/12. O desenvolvimento dos respectivos produtos permanece fora do recorte desta entrega.

3.2 Referências de aquisição e limites de uso

Dataset: *Brazilian E-Commerce Public Dataset by Olist*, publicado pela Olist no Kaggle [8]. Foi adquirido diretamente pelo endpoint público oficial em 05/10/2026. A API informa versão 2 e última atualização em 01/10/2021. Datas de atualização do repositório não se confundem com datas das transações. O manifesto local registra URL, horário UTC, tamanho e SHA-256 dos arquivos.

As compras observadas abrangem **04/09/2016 a 17/10/2018**; o pacote contém 99.441 pedidos. A fonte apresenta o conjunto como dados comerciais reais anonimizados e informa substituição de referências a empresas e parceiros nos textos de avaliação [8]. Não há afirmação de que o recorte cubra todas as transações da empresa.

A licença informada é CC BY-NC-SA 4.0: atribuição, uso não comercial e compartilhamento de adaptações dos dados sob a mesma licença [8,11]. A publicação como dados anonimizados não será interpretada como autorização para reidentificação. O PDF utiliza agregados e não reproduz IDs, CEPs ou comentários individuais.

A aquisição utiliza o endpoint público oficial do Kaggle e fontes institucionais. O registro das fontes e dos metadados permite conferir a procedência das informações e distinguir os fatos documentados dos resultados calculados.

4. Etapa 2: organização e problema do estudo

4.1 Apresentação da empresa

Tabela 4 - Caracterização da Olist e lacunas documentais

Item	Informação verificada / limite
Nome e segmento	Olist. Ecossistema de soluções para varejo; o objeto deste estudo são os pedidos históricos da Olist Store em marketplaces [8,9].
Missão / propósito	A página institucional declara o propósito de fortalecer negócios e impulsionar vidas [9].
Visão	Uma formulação autônoma explicitamente rotulada como visão não foi encontrada nas fontes consultadas. Não foi criada uma declaração substituta.
Valores	Praticidade, dinamismo, coragem, empatia e realização, conforme a página institucional [9].
Posicionamento / market share	A empresa se apresenta como ecossistema de soluções para o varejo [9]. Participação percentual de mercado, com denominador e período comparáveis, não encontrada nas fontes consultadas.
Colaboradores	Quadro atual não encontrado com data de referência confirmada. Uma página oficial exibe 420 colaboradores em narrativa sobre junho de 2020; apesar da data de página de 2025, o texto é histórico e não comprova quadro atual [10].
Iniciativas de dados / IA	A página de agentes descreve a Lis como integrada ao ERP, com consulta a dados, automação de análises e geração de gráficos e relatórios. São declarações da empresa, não desempenho validado neste estudo [15].
Trabalhos destacados	Publicação do dataset no Kaggle [8] e oferta de agentes de IA [15]. A página institucional também registra aquisição de Tiny e Vnda em 2021 e lançamento de Envios em 2024 [9].

A apresentação institucional corresponde às páginas consultadas em 05/10/2026. Os pedidos analisados pertencem a 2016-2018. Não se atribuem tecnologias atuais, aquisições posteriores ou resultados do ecossistema atual às transações históricas.

4.2 Problema e perguntas específicas

O gap explorado é a ausência, nos arquivos separados, de uma visão única que associe cumprimento de prazo e satisfação. Perguntas: qual a distribuição do tempo de entrega? Qual a frequência de atraso? Como se distribuem as notas? Os pedidos atrasados têm proporção diferente de avaliações baixas? Quais estados apresentam diferentes frequências e volumes de atraso? O frete apresenta associação com satisfação?

5. Metadados: origem, estrutura e recorte

Tabela 5 - Inventário completo dos arquivos oficiais

Arquivo CSV	Linhas	Colunas	Uso na análise
olist_customers_dataset.csv	99.441	5	Selecionado
olist_geolocation_dataset.csv	1.000.163	5	Fora do recorte
olist_order_items_dataset.csv	112.650	7	Selecionado
olist_order_payments_dataset.csv	103.886	5	Selecionado
olist_order_reviews_dataset.csv	99.224	7	Selecionado
olist_orders_dataset.csv	99.441	8	Selecionado
olist_products_dataset.csv	32.951	9	Fora do recorte
olist_sellers_dataset.csv	3.095	4	Fora do recorte
product_category_name_translation.csv	71	2	Fora do recorte

Fonte: contagem dos arquivos oficiais adquiridos [8]. Há 52 colunas distribuídas entre nove arquivos; esse total não corresponde à dimensão de uma tabela já integrada. Os cinco arquivos selecionados possuem 32 atributos de origem. Geolocalização, produtos, vendedores e tradução de categorias não são necessários para responder às perguntas delimitadas; o recorte por estado usa a tabela de clientes.

Tabela 6 - Metadados gerais e validade

Aspecto	Registro
Formato e origem	CSV, codificação UTF-8, separador vírgula; dados públicos do Kaggle, publicados pela Olist.
Proprietário / disponibilizador	Olist; plataforma de distribuição: Kaggle. A licença da fonte rege o uso.
Período e validade	Compras de 04/09/2016 a 17/10/2018. Recorte válido para descrição histórica; não sustenta diagnóstico atual sem novos dados.
Sensibilidade	Fonte declara anonimização. Ainda há identificadores, prefixos de CEP, cidades e texto livre; esses atributos não são publicados individualmente no PDF.
Moeda e fuso horário	Não foi encontrado código explícito de moeda nem fuso dos timestamps nos CSVs/API acessados. Valores são indicados em UM; diferenças temporais preservam o relógio original, sem conversão de fuso.
Restrições	Uso educacional não comercial, atribuição e licença de adaptações conforme CC BY-NC-SA 4.0; sem tentativas de reidentificação.
Granularidade	Pedidos: pedido; clientes: customer_id associado a pedido; itens: item de pedido; pagamentos: evento de pagamento; avaliações: resposta registrada.

A data-limite de envio e as avaliações podem ultrapassar o período das compras; seus intervalos serão apresentados no dicionário. Datas muito posteriores ao recorte não são automaticamente corrigidas sem evidência da origem.

6. Dicionário e perfil de todos os atributos

Tabela 7 - Pedidos: oito atributos e perfil inicial

Atributo	Tipo	Definição / valores observados	NAs	Distintos
order_id	Texto	Identificador do pedido; chave principal em pedidos e chave de integração nas tabelas filhas.	0	99.441
customer_id	Texto	Identificador do cliente associado a um pedido; chave para clientes. Não representa, sozinho, pessoa única.	0	99.441
order_status	Texto	Status registrado do pedido, variável categórica nominal.	0	8
order_purchase_timestamp	Data/hora	Data e hora da compra; referência de início do tempo de entrega. Intervalo: 2016-09-04 a 2018-10-17.	0	98.875
order_approved_at	Data/hora	Data e hora de aprovação do pedido. Intervalo: 2016-09-15 a 2018-09-03.	160	90.733
order_delivered_carrier_date	Data/hora	Data e hora registrada da entrega à transportadora; utilizada na auditoria de cronologia. Intervalo: 2016-10-08 a 2018-09-11.	1.783	81.018
order_delivered_customer_date	Data/hora	Data e hora registrada da entrega ao cliente. Intervalo: 2016-10-11 a 2018-10-17.	2.965	95.664
order_estimated_delivery_date	Data/hora	Data prevista de entrega; pontualidade considera todo esse dia de calendário. Intervalo: 2016-09-30 a 2018-11-12.	0	459

N = 99.441 linhas de origem para cada atributo; exemplares válidos = N menos NAs. Distintos exclui NAs. As definições são a interpretação operacional da nomenclatura e documentação da fonte; intervalos e contagens foram calculados nos CSVs. IDs, CEPs e categorias não recebem variância ou outliers numéricos.

Tabela 8 - Clientes: cinco atributos e perfil inicial

Atributo	Tipo	Definição / valores observados	NAs	Distintos
customer_id	Texto	Identificador do cliente associado a um pedido; chave para clientes. Não representa, sozinho, pessoa única.	0	99.441
customer_unique_id	Texto	Identificador que permite reconhecer o mesmo cliente em pedidos diferentes [8].	0	96.096
customer_zip_code_prefix	Texto	Cinco primeiros dígitos do CEP do cliente; preservados como texto.	0	14.994
customer_city	Texto	Nome de cidade registrado; categórico nominal.	0	4.119
customer_state	Texto	UF do cliente; categoria nominal utilizada nas comparações de destino.	0	27

N = 99.441 linhas de origem para cada atributo; exemplares válidos = N menos NAs. Distintos exclui NAs. As definições são a interpretação operacional da nomenclatura e documentação da fonte; intervalos e contagens foram calculados nos CSVs. IDs, CEPs e categorias não recebem variância ou outliers numéricos.

6.1 Itens e pagamentos

Tabela 9 - Itens: sete atributos e perfil inicial

Atributo	Tipo	Definição / valores observados	NAs	Distintos
order_id	Texto	Identificador do pedido; chave principal em pedidos e chave de integração nas tabelas filhas.	0	98.666
order_item_id	Texto	Posição/identificador do item dentro do pedido; preservado como texto, não usado como medida.	0	21
product_id	Texto	Identificador do produto; preservado, sem integração de categorias neste recorte.	0	32.951
seller_id	Texto	Identificador do vendedor do item; preservado, sem atribuição de desempenho individual.	0	3.095
shipping_limit_date	Data/hora	Data/hora limite de envio registrada para o item; inventariada, não usada para definir atraso ao cliente. Intervalo: 2016-09-19 a 2020-04-09.	0	93.318
price	Real	Valor monetário do item, em UM; somado por pedido. Mín./máx.: 0,85 / 6.735,00.	0	5.968
freight_value	Real	Valor monetário de frete do item, em UM; somado por pedido. Mín./máx.: 0,00 / 409,68.	0	6.999

N = 112.650 linhas de origem para cada atributo; exemplares válidos = N menos NAs. Distintos exclui NAs. As definições são a interpretação operacional da nomenclatura e documentação da fonte; intervalos e contagens foram calculados nos CSVs. IDs, CEPs e categorias não recebem variância ou outliers numéricos.

Tabela 10 - Pagamentos: cinco atributos e perfil inicial

Atributo	Tipo	Definição / valores observados	NAs	Distintos
order_id	Texto	Identificador do pedido; chave principal em pedidos e chave de integração nas tabelas filhas.	0	99.440
payment_sequential	Inteiro	Sequência/identificador do pagamento no pedido; sem interpretação como medida contínua. Mín./máx.: 1,00 / 29,00.	0	29
payment_type	Texto	Categoria de meio de pagamento registrada.	0	5
payment_installments	Inteiro	Número de parcelas registrado; quantitativo discreto. Zero é valor observado, não imputado. Mín./máx.: 0,00 / 24,00.	0	24
payment_value	Real	Valor monetário do evento de pagamento, em UM; somado por pedido. Mín./máx.: 0,00 / 13.664,08.	0	29.077

N = 103.886 linhas de origem para cada atributo; exemplares válidos = N menos NAs. Distintos exclui NAs. As definições são a interpretação operacional da nomenclatura e documentação da fonte; intervalos e contagens foram calculados nos CSVs. IDs, CEPs e categorias não recebem variância ou outliers numéricos.

6.2 Avaliações e medidas de origem

Tabela 11 - Avaliações: sete atributos e perfil inicial

Atributo	Tipo	Definição / valores observados	NAs	Distintos
review_id	Texto	Identificador da avaliação; pode se repetir e não é usado isoladamente para eliminar pedidos.	0	98.410
order_id	Texto	Identificador do pedido; chave principal em pedidos e chave de integração nas tabelas filhas.	0	98.673
review_score	Inteiro	Nota ordinal de 1 a 5; 1 ou 2 define avaliação baixa neste estudo. Mín./máx.: 1,00 / 5,00.	0	5
review_comment_title	Texto	Título em texto livre, opcional; inventariado, não submetido a NLP nem reproduzido.	87.656	4.527
review_comment_message	Texto	Comentário em texto livre, opcional; inventariado, não submetido a NLP nem reproduzido.	58.247	36.159
review_creation_date	Data/hora	Data de criação/envio da pesquisa de avaliação registrada na fonte. Intervalo: 2016-10-02 a 2018-08-31.	0	636
review_answer_timestamp	Data/hora	Data e hora da resposta; primeiro critério para escolher a avaliação mais recente. Intervalo: 2016-10-07 a 2018-10-29.	0	98.248

N = 99.224 linhas de origem para cada atributo; exemplares válidos = N menos NAs. Distintos exclui NAs. As definições são a interpretação operacional da nomenclatura e documentação da fonte; intervalos e contagens foram calculados nos CSVs. IDs, CEPs e categorias não recebem variância ou outliers numéricos.

Tabela 12 - Medidas dos atributos quantitativos de origem

Variável	n válido	Média	Mediana	Variância	Desvio	Outliers
Preço por item (UM)	112.650	120,65	74,99	33.721,42	183,63	8.427
Frete por item (UM)	112.650	19,99	16,26	249,84	15,81	12.134
Pagamento por evento (UM)	103.886	154,10	100,00	47.303,67	217,49	7.981
Parcelas por pagamento	103.886	2,85	1,00	7,22	2,69	6.313

Variância amostral (divisor n - 1); outliers pela regra 1,5 × IQR. Estatísticas dessa tabela têm granularidade de item ou evento de pagamento e não devem ser confundidas com os valores por pedido das tabelas seguintes. Notas ordinais são detalhadas por frequências; identificadores numéricos não recebem média. A distribuição de pagamentos será caracterizada também por categorias.

7. Pipeline e preparação dos dados

7.1 Pensamento computacional aplicado

Tabela 13 - Decomposição e implementação do processo

Princípio	Aplicação
Decomposição	Separar aquisição, qualidade, integração, descrição logística, satisfação e comparações geográficas.
Padrões	Buscar variações de prazo, frequência de atrasos, concentração das notas e associações entre medidas.
Abstração	Utilizar uma linha por pedido e agregados; excluir localização precisa e texto livre da interpretação principal.
Algoritmo	Executar validações, agregações, junções, variáveis derivadas, estatísticas e visualizações de modo reproduzível.

Fluxo de dados: fonte oficial → arquivos CSV preservados + manifesto → perfil e validação de chaves/tipos → agregação independente dos itens e pagamentos → escolha da avaliação mais recente → junções à tabela de pedidos e clientes → variáveis derivadas e coortes → estatísticas/gráficos → proposta analítica e PDF.

Pedidos integram-se a clientes por *customer_id*, validando cardinalidade muitos-para-um. Itens e pagamentos são primeiro agregados por *order_id*; cada agregado e a avaliação escolhida integram-se aos pedidos em relações um-para-um. As junções à esquerda preservam todos os pedidos. Não se realiza a junção direta entre linhas de itens e pagamentos, pois ela multiplicaria valores.

Foram observados 9.803 pedidos com múltiplos itens e 2.961 com múltiplos pagamentos. A tabela final preserva 99.441 linhas e unicidade de *order_id*. Os totais globais de itens, frete e pagamentos reconciliam com as tabelas de origem.

As avaliações possuem 547 pedidos com mais de uma resposta. Ordenaram-se as respostas por *review_answer_timestamp*, *review_creation_date* e *review_id*, mantendo a última por pedido; a ordenação é estável. Foram afastadas 551 linhas excedentes apenas dessa seleção analítica, preservando o arquivo original. Em 202 pedidos, as respostas têm notas diferentes: a regra influencia a medida de satisfação e deve permanecer explícita.

7.2 Critérios de qualidade

IDs são preservados como texto, valores como números e datas convertidas com registro de falhas. Não se imputa ausência com zero. Dados incoerentes são quantificados e não corrigidos por suposição. Nenhum outlier é removido automaticamente. A auditoria não encontrou falhas de conversão de datas nem duplicações de linhas completas nos cinco arquivos selecionados.

8. Variáveis derivadas e populações analíticas

Tabela 14 - Regras dos indicadores por pedido

Variável	Definição e unidade
Tempo de entrega	(Data/hora de entrega ao cliente - data/hora da compra) / 86.400 segundos. Unidade: dias fracionários.
Desvio do prazo previsto	Data de calendário da entrega menos data prevista normalizada. Unidade: dias; negativo = antecipação, zero = mesmo dia, positivo = atraso.
Pedido atrasado	Desvio do prazo previsto > 0. Entrega em qualquer horário do dia previsto é pontual.
Valor dos itens	Soma de price de todos os itens do pedido, em UM.
Frete total	Soma de freight_value de todos os itens do pedido, em UM.
Pagamento total	Soma de payment_value de todos os eventos do pedido, em UM. Não é receita líquida da Olist.
Frete / itens	100 × frete total / valor dos itens; unidade %. Só é definido com valor dos itens > 0.
Quantidade de itens	Número de linhas de itens no pedido; usado para auditoria da granularidade.
Avaliação baixa	Nota selecionada igual a 1 ou 2; definição operacional do estudo, não um critério atribuído à empresa.

A coorte logística requer status *delivered*, datas de compra, entrega e estimativa presentes e entrega/estimativa não anteriores à compra. Registros sem esses requisitos permanecem no perfil geral, mas não entram no cálculo de prazo ou atraso. A data à transportadora não define o indicador de atraso; suas inconsistências são reportadas e não apagadas.

Tabela 15 - Coortes e exclusões explícitas

População / condição	Pedidos
Todos os pedidos	99.441
Status entregue	96.478
Outros status	2.963
Entregues sem data de entrega: excluídos da logística	8
Coorte logística válida	96.470
Logística válida sem avaliação: excluídos da comparação de notas	646
Logística válida com avaliação	95.824
Todos os pedidos com avaliação selecionada	98.673
Todos os pedidos sem avaliação	768

As estatísticas monetárias gerais usam todos os pedidos com o atributo disponível, independentemente de status. Pearson utiliza a coorte logística e pares completos; Spearman e comparações de notas usam a coorte logística avaliada, com exclusão por par. O tamanho de cada análise é apresentado junto aos resultados.

9. AED: qualidade e caracterização geral

Tabela 16 - Auditoria de integridade e ocorrências

Verificação	Resultado	Tratamento / interpretação
IDs principais e chaves filhas	Sem duplicação em order_id de pedidos ou customer_id; chaves de item e pagamento únicas	Junções com cardinalidade validada; nenhuma referência de pedido órfã nas tabelas filhas.
review_id repetido	814 linhas excedentes	Não remover pedidos por review_id; selecionar resposta por order_id.
Entrega à transportadora anterior à compra	166	Inconsistência cronológica registrada; não se corrige por suposição.
Entrega ao cliente anterior à transportadora	23	Inconsistência registrada. O prazo principal usa compra e entrega ao cliente.
Data de entrega em status não entregue	6	Preservar no perfil; excluir da coorte logística por status.
Pedidos sem itens / sem pagamento	775 / 1	Manter ausentes após integração; não converter para zero.
Pagamentos diferentes de itens + frete	303 de 98.665	Diferença absoluta > 0,01 UM. Motivo não disponível: não presumir desconto, fraude ou erro.
Frete zero / pagamento zero na origem	383 / 9	Valores observados mantidos; não são NAs. Pagamentos zero são eventos, não necessariamente pedidos com total zero.

Não foram encontrados preços, fretes ou pagamentos negativos; nenhuma nota fora de 1-5; nenhuma data de entrega ao cliente ou estimativa anterior à compra. O arquivo de itens contém prazo de envio até 09/04/2020, posterior ao recorte de compras. Essa ocorrência é registrada como limite de validade do atributo, sem alteração do valor original.

A divergência de pagamentos ocorre em 0,31% dos pedidos comparáveis. Não se exige igualdade em cada pedido para afirmar a reconciliação global entre agregados e suas próprias tabelas de origem: são duas verificações distintas.

9.1 Ausências e texto livre

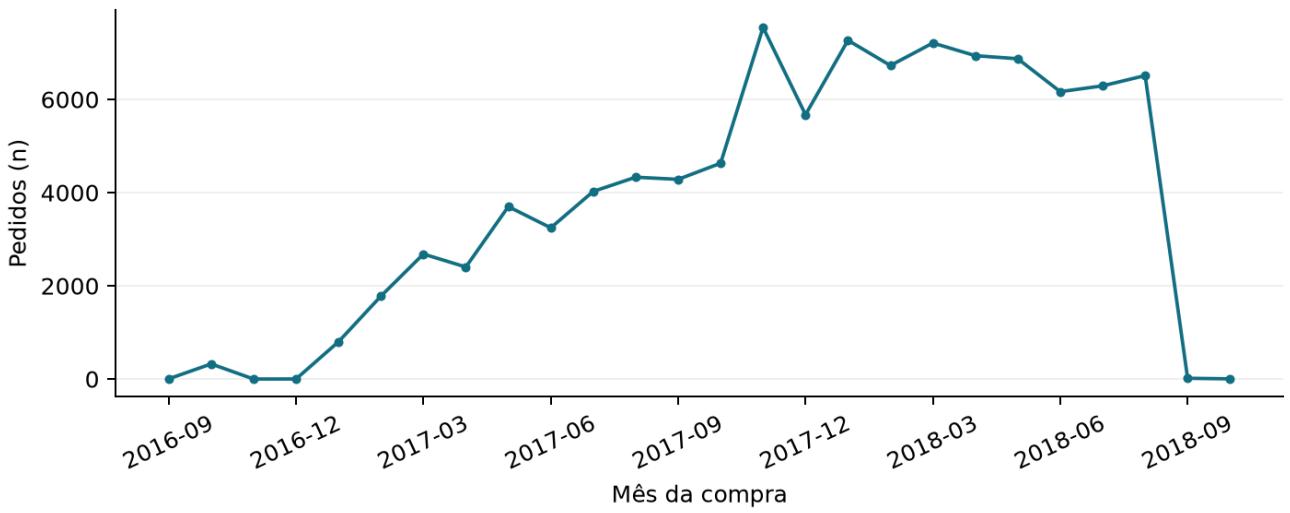
Na tabela de pedidos, há 160 aprovações ausentes, 1.783 datas de transportadora ausentes e 2.965 datas de entrega ao cliente ausentes. Parte das ausências é compatível com status sem conclusão; ausência sozinha não comprova erro. Nas avaliações originais, faltam 87.656 títulos e 58.247 comentários. A falta de comentário não é tratada como insatisfação.

10. AED: frequências e evolução dos pedidos

Tabela 17 - Distribuição dos status em todos os pedidos

Status original	Pedidos	% dos 99.441 pedidos
delivered	96.478	97,02%
shipped	1.107	1,11%
canceled	625	0,63%
unavailable	609	0,61%
invoiced	314	0,32%
processing	301	0,30%
created	5	0,01%
approved	2	0,00%

Figura 1 - Pedidos por mês de compra



Fonte: cálculo próprio sobre pedidos [8]. N = 99.441; todos os status; eixo horizontal = mês da compra, vertical = pedidos. Meses sem registros são incluídos com zero. O maior volume observado é novembro de 2017, com 7.544 pedidos. Não se atribui esse pico a promoções sem variável ou fonte que comprove a causa.

O início e o fim do recorte apresentam poucos registros: setembro/outubro de 2018 têm 16 e 4 pedidos. A forte queda nos meses finais não comprova retração do negócio; pode decorrer do limite de cobertura da base. Não se calcula previsão, taxa de crescimento da empresa ou comparação de anos completos a partir desse recorte.

10.1 Formas de pagamento e categorias

A frequência de payment_type é medida por evento de pagamento, não por pedido exclusivo. Um pedido pode possuir mais de um meio de pagamento, portanto somar eventos não produz número de pedidos. As cidades são usadas somente como metadado: diferenças de grafia não foram padronizadas e não se fazem rankings municipais.

Os três meios mais frequentes na origem são credit_card: 76.795 eventos, boleto: 19.784 eventos, voucher: 5.775 eventos. O perfil completo e as frequências por coluna estão preservados nos resultados locais.

11. AED: posição e dispersão por pedido

Tabela 18 - Medidas de posição e intervalo

Variável	n válido	Média	Mediana	Mínimo	Máximo	Amplitude
Entrega (dias)	96.470	12,56	10,22	0,53	209,63	209,10
Desvio do prazo (dias)	96.470	-11,88	-12,00	-147,00	188,00	335,00
Itens (UM)	98.666	137,75	86,90	0,85	13.440,00	13.439,15
Frete (UM)	98.666	22,82	17,17	0,00	1.794,96	1.794,96
Pagamento (UM)	99.440	160,99	105,29	0,00	13.664,08	13.664,08
Frete / itens (%)	98.666	30,84	22,44	0,00	2.144,71	2.144,71

Tabela 19 - Separatrizes e moda

Variável	Q1	Q3	P10	P90	P95	Moda
Entrega (dias)	6,77	15,72	4,16	23,10	29,27	57 empates
Desvio do prazo (dias)	-17,00	-7,00	-22,00	-2,00	3,00	-14,00
Itens (UM)	45,90	149,90	25,00	269,90	399,90	59,90
Frete (UM)	13,85	24,04	9,34	39,50	54,96	15,10
Pagamento (UM)	62,01	176,97	39,60	308,24	452,99	77,57
Frete / itens (%)	13,19	38,02	7,80	62,25	83,94	0,00

Tabela 20 - Medidas de dispersão

Variável	Variância	Desvio padrão	IQR	CV (%)
Entrega (dias)	91,13	9,55	8,95	76,02
Desvio do prazo (dias)	103,68	10,18	10,00	Não aplicável
Itens (UM)	44.371,38	210,65	104,00	152,91
Frete (UM)	468,76	21,65	10,19	94,86
Pagamento (UM)	49.262,36	221,95	114,96	137,87
Frete / itens (%)	990,75	31,48	24,83	102,07

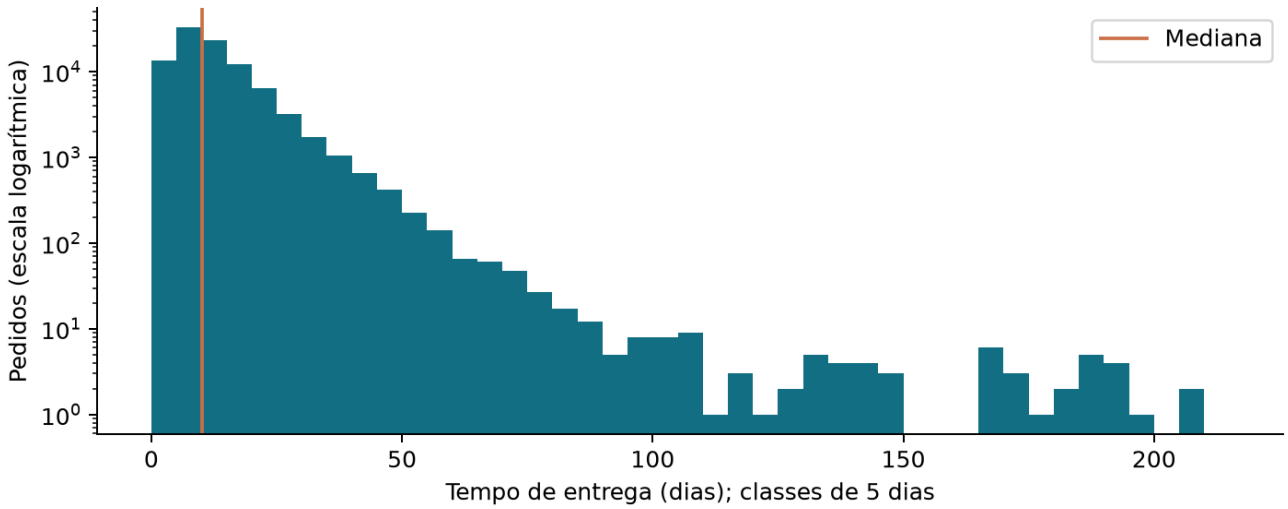
Fonte: cálculos próprios [8]. Entrega e desvio usam a coorte logística (96.470). Valores monetários e razão usam o atributo disponível na base de todos os pedidos; NAs são 775 em itens/frete/razão e 1 em pagamento. Variância amostral usa divisor n - 1 e unidade ao quadrado; desvio tem a unidade original. Quartis e percentis usam interpolação linear. O desvio do prazo inclui antecipações negativas, razão pela qual não recebe CV.

A entrega tem média de 12,56 e mediana de 10,22 dias. O P95 é 29,27 dias: aproximadamente 95% dos pedidos da coorte têm prazo até esse valor. No tempo fracionário, há 57 valores empatados como moda, cada um com frequência 3; a moda não é uma medida representativa de prazo típico.

Itens, frete e pagamento têm médias superiores às medianas e elevada dispersão. Medianas e percentis complementam as médias; os extremos são preservados. Frete/itens pode superar 100%, pois seu denominador contém somente os itens, não o pagamento total.

12. AED: distribuição e outliers

Figura 2 - Distribuição do tempo de entrega



Fonte: cálculo próprio [8]. N = 96.470 pedidos entregues com datas válidas. Classes de cinco dias; eixo vertical logarítmico para preservar a visibilidade da cauda; linha indica mediana. Todos os prazos estão representados, sem corte dos extremos. O máximo observado é 209,63 dias. A concentração dos prazos menores e a cauda prolongada mostram por que uma média isolada é insuficiente.

Tabela 21 - Limites e ocorrências de outliers

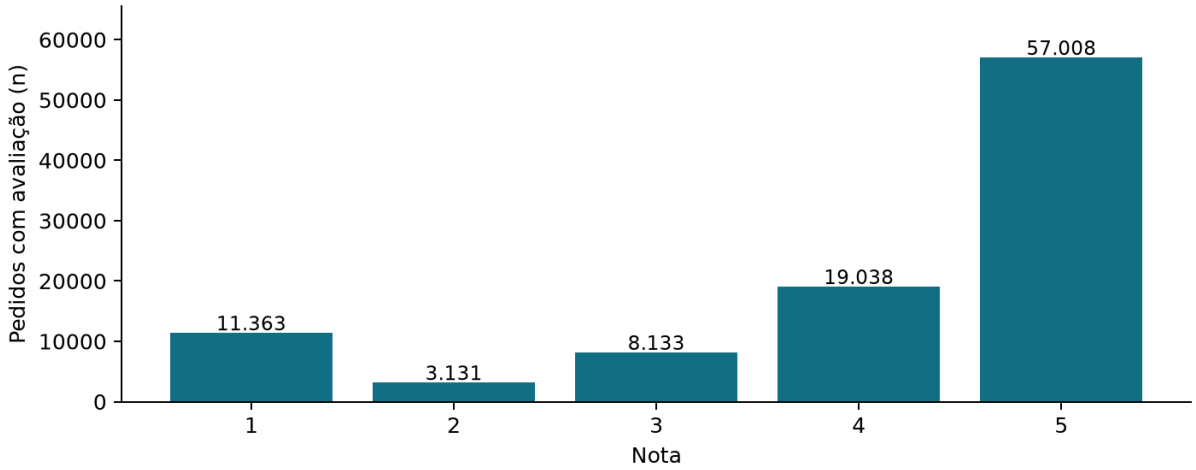
Variável	Limite inferior	Limite superior	Outliers (n)	% válidos
Entrega (dias)	-6,66	29,15	4.896	5,08%
Desvio do prazo (dias)	-32,00	8,00	4.297	4,45%
Itens (UM)	-110,10	305,90	7.913	8,02%
Frete (UM)	-1,44	39,33	9.941	10,08%
Pagamento (UM)	-110,43	349,41	7.866	7,91%
Frete / itens (%)	-24,06	75,27	6.563	6,65%

Outliers são identificados abaixo de Q1 - 1,5 × IQR ou acima de Q3 + 1,5 × IQR [6,12]. Os limites são uma regra exploratória, não um diagnóstico de erro nem uma promessa de normalidade. Alguns limites inferiores são negativos apesar de a variável só assumir valores não negativos; nesses casos, não há ocorrências abaixo de zero.

O prazo de entrega possui 4.896 outliers, equivalentes a 5,08% da coorte. O desvio do prazo possui extremos de antecipação e atraso; por isso, sua contagem de outliers não coincide com o número de pedidos atrasados. O boxplot das notas na seção seguinte permite observar a distribuição dos prazos sem apagar valores extremos.

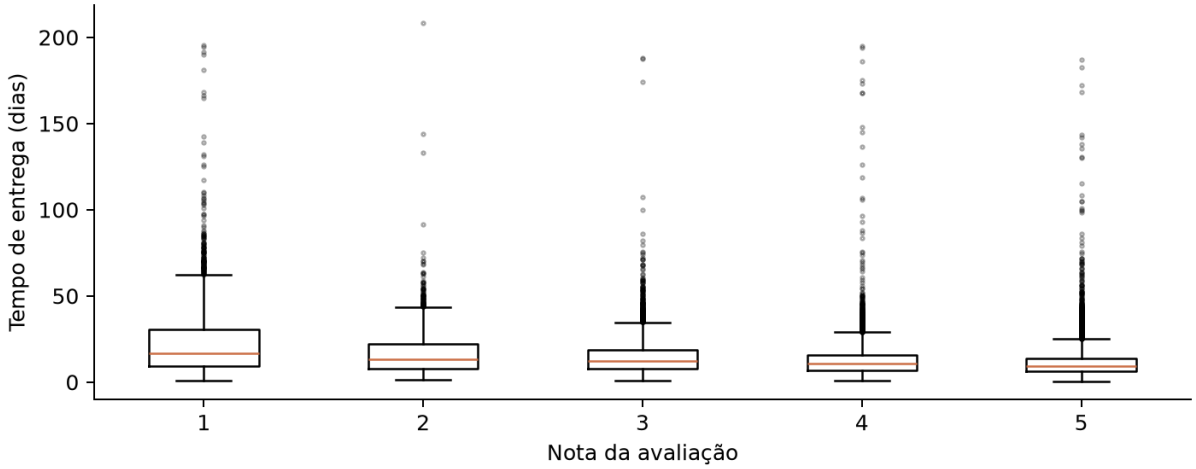
13. AED: avaliações e associação com atraso

Figura 3 - Frequência das notas selecionadas por pedido



Fonte: cálculo próprio [8]. N = 98.673 pedidos com avaliação selecionada, em todos os status; 768 sem avaliação estão fora do gráfico. Nota 5: 57.008 (57,77%); nota 1: 11.363 (11,52%). A mediana e a moda são 5. As frequências completas das notas são 1: 11.363 (11,52%), 2: 3.131 (3,17%), 3: 8.133 (8,24%), 4: 19.038 (19,29%), 5: 57.008 (57,77%).

Figura 4 - Tempo de entrega por nota de satisfação



Fonte: cálculo próprio [8]. N = 95.824 pedidos da coorte logística com avaliação. Eixo horizontal = nota ordinal; vertical = dias de entrega. Pontos fora dos bigodes são preservados. A distribuição de prazos para nota 1 apresenta valores tipicamente maiores que para nota 5; os grupos se sobrepõem e há extremos em todas as notas. O gráfico descreve associação, sem identificar a causa de cada avaliação.

14. AED: pontualidade e avaliações baixas

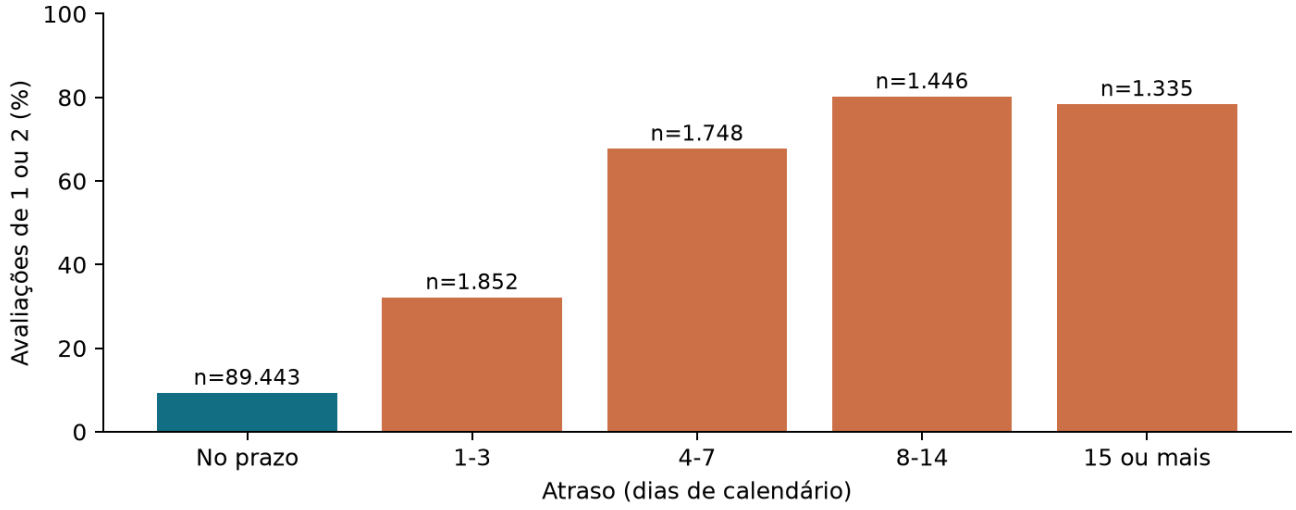
Dos 96.470 pedidos da coorte logística, 6.534 são atrasados (6,77%) e 89.936 são pontuais (93,23%). Pontual inclui entrega antecipada ou no dia previsto. Nas comparações abaixo, o denominador é o subconjunto com avaliação, e não todos os pedidos logísticos.

Tabela 22 - Comparação entre pedidos pontuais e atrasados com avaliação

Grupo	n avaliado	Mediana da nota	Notas 1-2 (n)	Notas 1-2 (%)	Mediana entrega
Pontuais	89.443	5	8.289	9,27	9,80 dias
Atrasados	6.381	1	3.983	62,42	31,18 dias

A proporção de notas 1 ou 2 é 53,15 pontos percentuais maior entre atrasados. A mediana da avaliação passa de 5 no grupo pontual para 1 no grupo atrasado. Essas diferenças são descritivas; outros atributos do pedido e a seleção dos respondentes podem participar da associação.

Figura 5 - Avaliações baixas por faixa de atraso

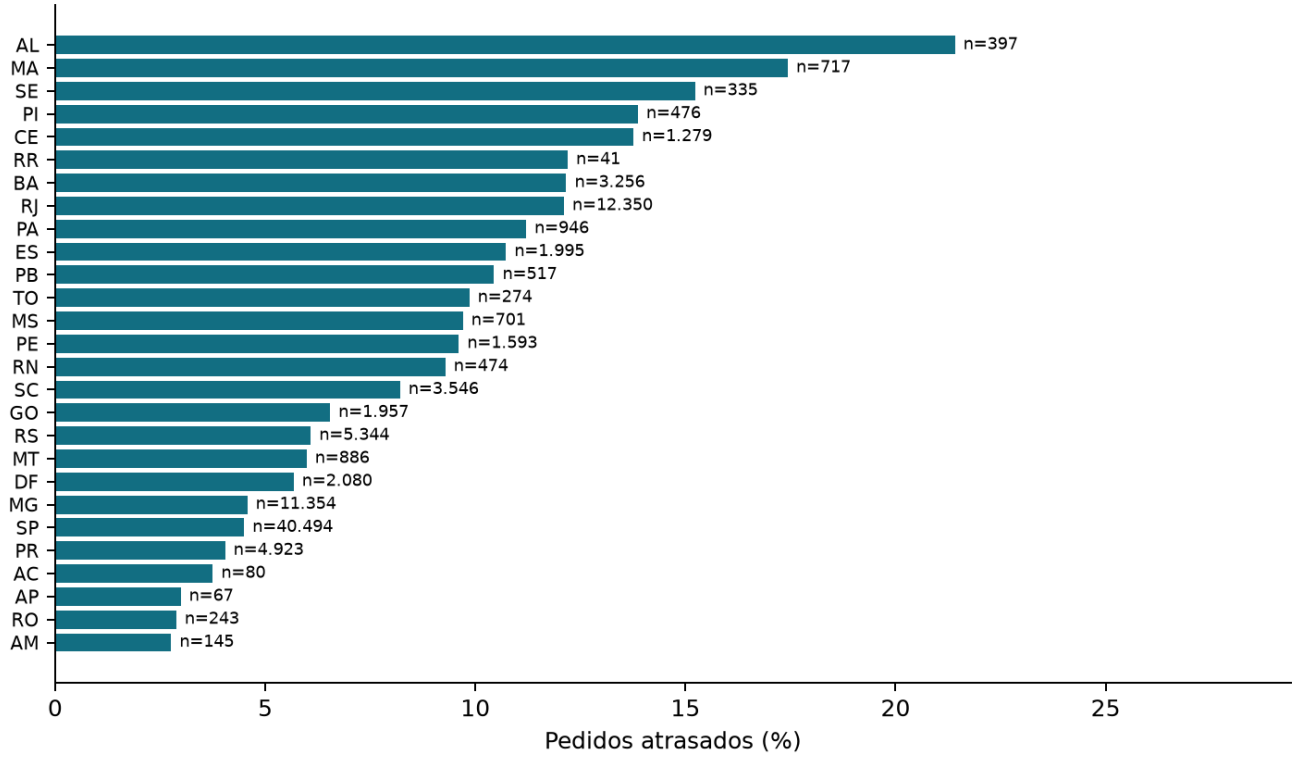


Fonte: cálculo próprio [8]. N = 95.824; apenas pedidos logísticos avaliados. O denominador de cada barra é informado sobre ela. Faixas são dias de calendário: pontual (desvio ≤ 0), 1-3, 4-7, 8-14 e 15 ou mais. Avaliação baixa é nota 1 ou 2. A comparação detalha o desvio do prazo, sem tratar atraso como única explicação de insatisfação.

Pedidos logísticos sem avaliação (646) não recebem nota estimada. Cancelamentos e pedidos sem conclusão não fazem parte dessa comparação de prazo; suas notas podem ser observadas na distribuição geral, mas não são confundidas com entregas pontuais.

15. AED: diferenças entre estados

Figura 6 - Percentual de atraso por UF do cliente



Fonte: cálculo próprio [8]. N = 96.470 pedidos logísticos válidos; total por UF indicado ao lado da barra. Trata-se do estado do cliente, não de rota, transportadora ou estado de origem. Estados com poucos registros podem apresentar percentuais instáveis. Não há comparação ajustada por produtos, distância ou composição dos pedidos.

Alagoas apresenta o maior percentual observado: 21,41%, em 397 pedidos (85 atrasos). São Paulo tem 4,49% de atraso, porém 1.820 ocorrências em 40.494 pedidos. Rio de Janeiro apresenta 12,11%, com 1.495 atrasos em 12.350 pedidos. A prioridade operacional proposta deve considerar tanto taxa quanto volume, em vez de ordenar somente pelo percentual.

15.1 Tabela de apoio das 27 UFs

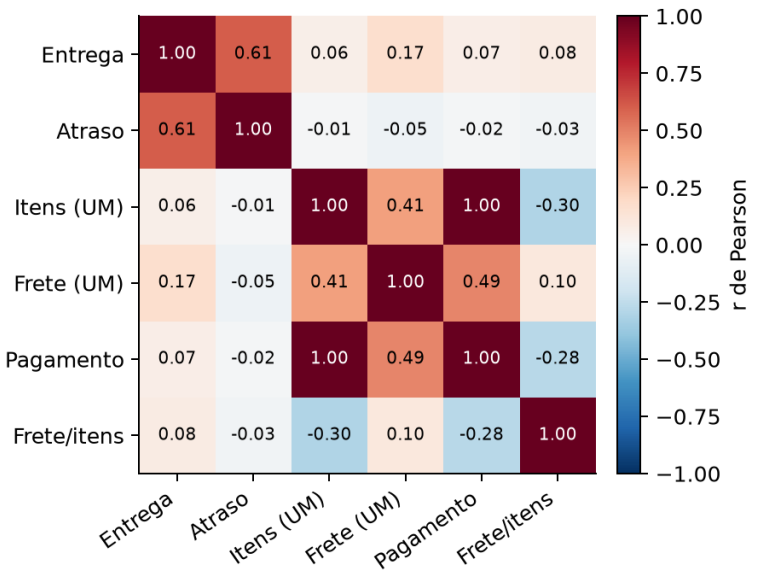
Tabela 23 - Volume, atraso e prazo mediano por UF

UF	Pedidos válidos	Atrasados	Atraso (%)	Entrega mediana (dias)
AL	397	85	21,41	22,33
MA	717	125	17,43	19,19
SE	335	51	15,22	18,01
PI	476	66	13,87	16,29
CE	1.279	176	13,76	18,21
RR	41	5	12,20	25,01
BA	3.256	396	12,16	16,91
RJ	12.350	1.495	12,11	12,04
PA	946	106	11,21	21,08
ES	1.995	214	10,73	13,64
PB	517	54	10,44	18,15
TO	274	27	9,85	15,87
MS	701	68	9,70	13,94
PE	1.593	153	9,60	15,70
RN	474	44	9,28	16,06
SC	3.546	291	8,21	13,01
GO	1.957	128	6,54	13,95
RS	5.344	325	6,08	13,18
MT	886	53	5,98	16,11
DF	2.080	118	5,67	11,36
MG	11.354	519	4,57	10,31
SP	40.494	1.820	4,49	7,21
PR	4.923	199	4,04	10,43
AC	80	3	3,75	18,36
AP	67	2	2,99	24,35
RO	243	7	2,88	17,58
AM	145	4	2,76	25,88

Fonte: cálculo próprio [8]. Ordenação decrescente do percentual de atraso. As somas dos pedidos e dos atrasos por estado reconciliam, respectivamente, com 96.470 e 6.534. Os valores são históricos e não constituem ranking atual de qualidade de serviços.

16. AED: relações entre variáveis

Figura 7 - Correlações de Pearson entre medidas por pedido



Fonte: cálculo próprio [8]. Coorte logística de 96.470 pedidos; exclusão por pares. Os denominadores dos pares variam de 96.469 a 96.470. As células mostram r de Pearson, entre -1 e 1. IDs e notas ordinais não compõem essa matriz. A associação entre valor de itens e pagamento decorre parcialmente da própria composição dos valores; não é descoberta causal.

Tabela 24 - Spearman entre nota e medidas do pedido

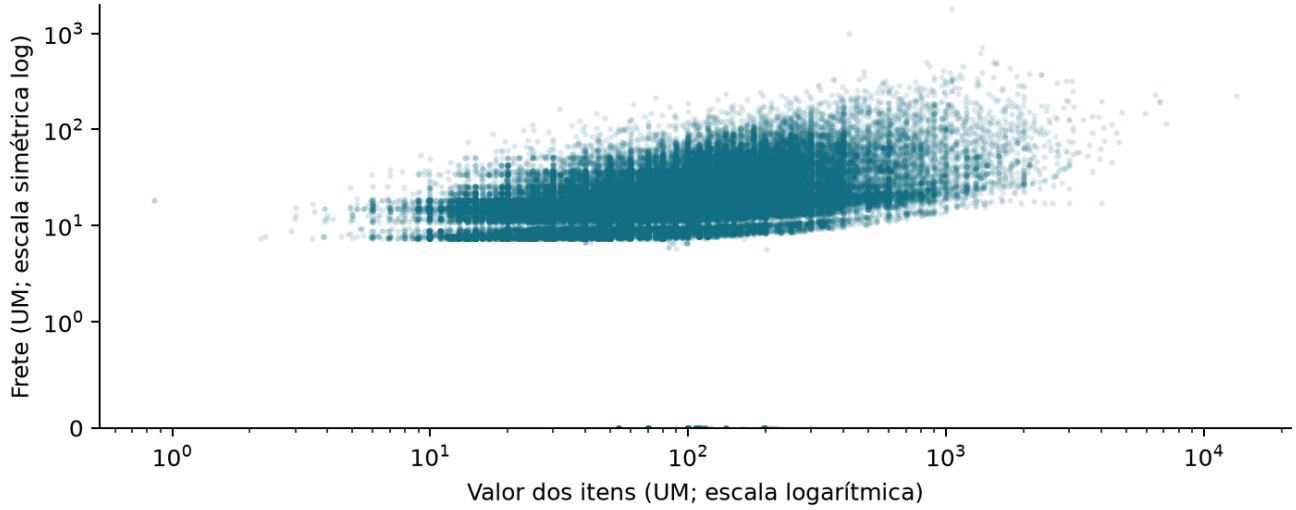
Medida relacionada à nota	n de pares	Coeficiente rho
Entrega (dias)	95.824	-0,2346
Desvio do prazo (dias)	95.824	-0,1764
Frete (UM)	95.824	-0,0882
Frete / itens (%)	95.824	-0,0310
Itens (UM)	95.824	-0,0288

Spearman foi calculado como Pearson dos postos médios, preservando empates; essa formulação evita pressupor intervalos iguais entre notas ordinais [12]. A relação de maior magnitude entre as medidas avaliadas é a do tempo de entrega com a nota (rho = -0,2346). Frete total apresenta rho = -0,0882; frete/itens, -0,0310. Valores pequenos não sustentam afirmar que frete alto necessariamente determina nota baixa.

A associação linear e a monotônica sintetizam padrões diferentes. A comparação pontual/atrasado pode revelar diferenças relevantes mesmo quando a correlação global é de magnitude limitada. Não foram aplicados testes de hipótese, regressão ajustada ou estimativas causais; não se atribui significância estatística sem esses procedimentos.

17. AED: valores, dispersão e síntese

Figura 8 - Dispersão de valor dos itens e frete total



Fonte: cálculo próprio [8]. N = 96.470 pedidos logísticos, com valores disponíveis. Cada ponto corresponde a um pedido; transparência reduz sobreposição. Eixo horizontal logarítmico; vertical simétrico logarítmico para preservar fretes zero. Valores em UM. Os pontos não foram amostrados nem tiveram extremos excluídos.

O gráfico evidencia ampla variação do frete para pedidos de valores semelhantes. A razão frete/itens descreve o peso relativo do frete na compra, mas não distingue distância, peso, modalidade ou política comercial, variáveis não incorporadas ao recorte. Sem elas, não se pode concluir que determinada cobrança seja inadequada ou atribuir a dispersão à transportadora.

Tabela 25 - Respostas às perguntas de pesquisa

Pergunta	Evidência obtida / alcance
Qual o prazo típico?	Mediana 10,22 dias; P95 29,27; média 12,56. Há cauda longa e outliers preservados.
Qual a frequência de atraso?	6.534 de 96.470 pedidos logísticos: 6,77%, considerando pontual todo o dia previsto.
Como atraso e notas se associam?	Notas 1-2 em 62,42% dos atrasados avaliados e 9,27% dos pontuais avaliados; diferença de 53,15 p.p.
Há diferenças geográficas?	Sim, no recorte por UF. AL tem taxa 21,41%; SP concentra 1.820 atrasos. Comparações não são ajustadas.
Frete se associa à nota?	Spearman do frete total com nota: -0,0882; da razão frete/itens: -0,0310. Associação de pequena magnitude.
É possível apontar causas?	Não com esta AED. Transportadora, causas da nota, custos e políticas comerciais não foram demonstrados.

18. Proposta de solução analítica

18.1 Produto e público de uso

Propõe-se um relatório periódico de qualidade dos dados, pontualidade e satisfação, destinado a analistas e responsáveis por atendimento/logística. O produto deve permitir comparar taxa e volume de atrasos por UF, observar caudas de prazo e acompanhar notas em grupos de entrega. Nesta etapa, a AED histórica e a especificação estão concluídas; não há implantação em produção ou ganho operacional medido.

Tabela 26 - Indicadores propostos e regras de uso

Indicador	Cálculo / uso recomendado
Pontualidade	Pedidos com desvio ≤ 0 / pedidos logísticos válidos. Exibir período, n e exclusões.
Prazo de entrega	Mediana, P90 e P95 de delivery_days. Comparar distribuições, evitando média isolada.
Avaliações baixas	Notas 1-2 / pedidos avaliados, separando pontuais, atrasados e faixas de atraso.
Prioridade por UF	Exibir simultaneamente taxa e quantidade absoluta de atraso. Destacar bases pequenas sem esconder o n.
Frete relativo	Mediana e P95 de frete/itens; investigar extremos com dados complementares, sem limite arbitrário de preço justo.
Qualidade e cobertura	NAs, cronologias incoerentes, pedidos sem itens, divergências monetárias e cobertura das avaliações.

18.2 Funcionamento e critérios de aceitação

O pipeline proposto reutiliza o fluxo documentado: novas extrações → validações → agregações por pedido → junções controladas → coortes e indicadores → relatório com fonte e período. Uma execução que apresente chaves principais duplicadas, pedidos órfãos ou falha de reconciliação deve interromper o cálculo e exigir revisão, em vez de publicar totais incorretos. O código implementa essas verificações.

Critérios de aceitação: uma linha por pedido; totais reconciliados com as tabelas de origem; denominadores disponíveis em cada indicador; ausências sem imputação silenciosa; regras de datas consistentes; saída reproduzível no notebook; distinção entre resultados históricos e recomendações. A validação do produto futuro com usuários do negócio e dados atuais não foi realizada e não é apresentada como realizada.

As evidências sugerem investigar casos de atraso prolongado e destinos com taxa elevada ou grande volume de ocorrências. Não se recomenda um percentual de redução ou retorno financeiro, pois os dados não demonstram quanto uma intervenção reduziria atrasos, aumentaria satisfação ou produziria receita. Nenhum sistema preditivo adicional é necessário para cumprir as etapas 1 e 2.

19. Limitações e reprodução

19.1 Limites da evidência

O conjunto é histórico, anonimizado e não possui plano de amostragem identificado. As fronteiras temporais têm cobertura incompleta. A satisfação é observada somente entre respondentes e depende da regra de seleção das avaliações. As diferenças geográficas não controlam produto, distância ou operação logística. Os timestamps não informam fuso na documentação acessada; indicadores preservam as datas originais. A moeda não foi explicitamente confirmada e é indicada como UM.

Há inconsistências de cronologia de expedição e divergências entre componentes monetários. Outliers podem refletir casos reais ou problemas de registro; não foi possível determinar suas causas. Comentários não foram analisados e não fornecem explicação validada das notas. Não há inferência causal, diagnóstico atual da empresa, lucro calculado, previsão de vendas ou participação de mercado estimada.

19.2 Materiais de reprodução e verificação

Os materiais de reprodução estão organizados no repositório github.com/hecorradini/Projeto-Aplicado-1, com README, aquisição, notebook Python documentado, script de análise, resultados, figuras e registro das fontes. O notebook contém comandos, bibliotecas, comentários metodológicos e saídas geradas pela mesma execução que fundamenta o PDF. Os arquivos originais permanecem preservados; hashes permitem identificar a versão adquirida.

A verificação executável mínima cobre múltiplos itens/pagamentos, seleção da avaliação mais recente, ausência de data e entrega no mesmo dia previsto. Na base real, foram verificadas unicidade, cardinalidade, ausência de referências órfãs e reconciliação dos totais. As estatísticas de Spearman usam postos médios e os gráficos mantêm os extremos, com escalas explicitadas.

Ambiente da análise: Python 3.12.14, pandas 3.0.1, NumPy 2.3.5 e Matplotlib 3.11.2. A composição usa ReportLab. Dados adquiridos em 05/10/2026; metadados oficiais informam versão 2 e atualização de 01/10/2021.

Referências

[1] LOPES, Fabio Silva. Projeto Aplicado I: texto de apoio, etapa 1. Material didático da disciplina, s.d. Arquivo: PROJ APLIC I TEXTO DE APOIO_Etapa1.pdf.

[2] LOPES, Fabio. Projeto Aplicado I: orientações iniciais. Material didático da disciplina, s.d. Arquivo: PROJ_APLIC_I_AULA_1_Orientacoes.pdf.

[3] LOPES, Fabio. Projeto Aplicado I: proposta e AED. Material didático da disciplina, s.d. Arquivo: PROJ_APLIC_I_AULA_2_Proposta e AED.pdf.

[4] OLIVEIRA, Rogério de. Análise Exploratória de Dados: aula 1. Material didático da disciplina, s.d. Introdução à AED e CRISP-DM.

[5] OLIVEIRA, Rogério de. Análise Exploratória de Dados: aula 2. Material didático da disciplina, s.d. Organização Tidy e manipulação de dados tabulares.

[6] OLIVEIRA, Rogério de. Análise Exploratória de Dados: aula 3. Material didático da disciplina, s.d. Estatística descritiva, outliers e correlação. Complemento: print A3 - Explorando conceitos.

[7] OLIVEIRA, Rogério de. Análise Exploratória de Dados: aula 4. Material didático da disciplina, s.d. Visualização de dados. Complemento: print A4 - Explorando conceitos.

[8] OLIST. Brazilian E-Commerce Public Dataset by Olist. Kaggle, versão 2; atualização informada pela API: 1 out. 2021. Base, descrição e metadados. Disponível em: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce . APIs oficiais de aquisição/metadados: https://www.kaggle.com/api/v1/datasets/download/olistbr/brazilian-ecommerce e https://www.kaggle.com/api/v1/datasets/view/olistbr/brazilian-ecommerce . Acesso e aquisição: 5 out. 2026.

[9] OLIST. Sobre a Olist. Página institucional, s.d. Disponível em: https://olist.com/sobre-nos/ . Acesso em: 5 out. 2026.

[10] OLIST. Olist no Estadão: O consumidor ficou mais exigente com o e-commerce. Página exibe 29 dez. 2025, mas o conteúdo citado descreve junho de 2020. Disponível em: https://olist.com/blog/olist/olist-news/perfil-do-consumidor-no-e-commerce/ . Acesso em: 5 out. 2026. Utilizada apenas como informação histórica sobre colaboradores.

[11] CREATIVE COMMONS. Attribution-NonCommercial-ShareAlike 4.0 International. Disponível em: https://creativecommons.org/licenses/by-nc-sa/4.0/ . Acesso em: 5 out. 2026.

[12] NAVARRO, Danielle. Learning Statistics with R. Capítulo 5: Descriptive statistics. Referência de 2019 indicada no material da disciplina; capítulo online consultado em: https://learningstatisticswithr.com/05-descriptives.html . Acesso em: 5 out. 2026.

[13] OLIVEIRA, Rogério de. Introdução à Visualização de Dados com Python. São Paulo: Mackenzie, 2021. Repositório do autor: https://github.com/Rogerio-mack/Visualizacao-de-Dados-em-Python . Acesso em: 5 out. 2026.

[14] FROM DATA TO VIZ. Find the graphic you need. Disponível em: https://www.data-to-viz.com/ . Acesso em: 5 out. 2026.

[15] OLIST. Agentes de IA da Olist. Página de apresentação da Lis e suas funcionalidades, s.d. Disponível em: https://olist.com/agentes/ . Acesso em: 5 out. 2026.

[16] RUBRICAS DE AVALIAÇÃO. Materiais de avaliação da disciplina para as entregas 1 e 2. Critérios de organização, repositório, cronograma, objetivos, metadados, proposta analítica, notebooks e AED, s.d.

Observação de rastreabilidade: números e gráficos de resultados são cálculos próprios sobre [8]; descrições institucionais são atribuídas às páginas oficiais. Datas desconhecidas dos materiais didáticos não foram inferidas. As rubricas [16] orientam a organização e os limites das entregas.